作业一：文本分类实现 • 实验报告

范一鸣 2313766

数据集：NYT News（business / politics / sports）

评价指标：Accuracy、Macro-F1 | 2026 年 10 月 9 日

一、任务概述

本次作业在 New York Times (NYT) 新闻数据集上完成三分类任务，分别使用三类文本表示方法训练分类器，并比较它们的表现：

- **Task 1 — 词袋模型**：Binary Bag of Words、Word Frequency，分类器为 Logistic Regression；
- **Task 2 — 词向量**：预训练 GloVe (100d)、在 AG News 上自训练的 Word2Vec (100d)、在 NYT 上自训练的 Word2Vec (100d)，文档向量取词向量平均，分类器同为 Logistic Regression；
- **Task 3 — 预训练语言模型**：微调 `google-bert/bert-base-uncased`（max_length=64，3 epochs）。

二、数据集与预处理

2.1 数据统计

数据集	条数	说明
NYT	11,519	三分类：sports 8,639 / politics 1,451 / business 1,429（类别不均衡，约 6:1）
AG News	90,000	仅 text 列，用于训练 Word2Vec

NYT 的文档比较长：平均约 638 词，中位数 672 词，最长 5,134 词。

2.2 数据划分

用固定随机种子 `seed = 42` 打乱 NYT 数据后按 80% / 10% / 10% 划分：

划分	条数	用途

Training Set	9,215	训练分类器 / 训练 Word2Vec(NYT) / 微调 BERT
Validation Set	1,151	BERT 按 Macro-F1 选择最优 checkpoint
Test Set	1,153	所有方法的最终评价

所有实验共用上述同一份划分，保证不同方法之间可以比较。

2.3 文本分词与词表

- **分词**：小写化后按正则 `[a-z0-9]+(?:'[a-z]+)?` 抽词。语料本身已经是小写的新闻文本，这样做与 `nltk.word_tokenize` 的效果基本一致。
- **词表**：Task 1 的词表 |V| = 66,266，只用训练集构建；测试集中没有出现过的词直接忽略，避免信息泄露。

三、实验设置

- **Logistic Regression**：`sklearn.LogisticRegression(max_iter=1000)`，其余超参默认，随机种子 42。
- **Word2Vec**：gensim，`vector_size=100, window=5, min_count=2, sg=0 (CBOW), epochs=5, seed=42`。AG News 版本使用全部 90,000 条文本；NYT 版本只用训练集的 9,215 条文本，避免测试集信息泄露。
- **GloVe**：官方 `glove.6B.100d.txt`（400,000 词）。文档向量 = 文档内所有"有词向量"的词的词向量平均；一个有效词都没有的文档取零向量。
- **BERT**：`bert-base-uncased`，`max_length=64`，`batch_size=32`，AdamW `lr=2e-5` 加线性 warmup（前 10% 步数），梯度裁剪 1.0，共 3 epochs；按验证集 Macro-F1 保留最优权重，最后在测试集上评价一次。

四、实验结果

全部结果都在 NYT Test Set（1,153 条）上测得：

任务	方法	表示维度	Accuracy	Macro-F1
Task 1	Binary Bag of Words	66,266	**0.9818**	0.9538
	Word Frequency	66,266	0.9809	**0.9542**
Task 2	Pre-trained GloVe（词向量平均）	100	0.9801	0.9484

	Word2Vec on AG News（词向量平均）	100	0.9801	0.9504
	Word2Vec on NYT（词向量平均）	100	0.9775	0.9445
Task 3	BERT-base-uncased（fine-tune）	—	0.9775	0.9522

BERT 三个 epoch 在验证集上的表现：epoch 1 acc=0.9713 / F1=0.9353；epoch 2 acc=0.9791 / F1=0.9548；epoch 3 acc=0.9818 / F1=0.9618。训练损失依次为 0.2899、0.0428、0.0155，收敛正常，最终测试使用 epoch 3 的权重。

五、结果分析

5.1 词袋模型（Task 1）

两种词袋表示的表现几乎一样（Accuracy 约 98.1%，Macro-F1 约 95.4%）。NYT 新闻里球队名、公司名、政治人物这类主题词的区分度很高，一个词是否出现就足够判断类别了，词频带来的额外计数信息作用不大。

5.2 词向量平均（Task 2）

三种 100 维词向量平均方法的 Accuracy 在 97.7%~98.0% 之间，比词袋模型略低。可能的原因有三点：平均操作把整篇文档压成一个 100 维向量，丢掉了词序，也稀释了强区分词的作用；没有词向量的词只能跳过，存在覆盖损失；在 9k 条 NYT 上训练的词向量语料偏小、词汇覆盖不足，所以成绩是三者中最低的。AG News 和 NYT 同为新闻语料、分布接近，因此在 AG News 上训练的 Word2Vec 与公开预训练的 GloVe 相当。

5.3 预训练语言模型（Task 3）

BERT 的微调过程是正常的：训练损失从第一个 epoch 的 0.29 降到第三个 epoch 的 0.015，验证集 Macro-F1 逐轮提高到 0.9618。但测试集 Accuracy（0.9775）和 Macro-F1（0.9522）没有超过词袋模型，主要原因还是 max_length=64 的限制：NYT 文档中位数约 672 词，64 个词只能覆盖全文开头的一小部分，而本任务的主题信号分散在全文各处，词袋向量恰好能覆盖整篇文档。另外这个三分类任务已经接近饱和，各方法的 Accuracy 都集中在 97.7%~98.2% 的很窄区间里，预训练模型能发挥的空间不大。如果允许更长的输入长度，BERT 的成绩应该还能提高。

5.4 关于 Macro-F1

所有方法的 Macro-F1 都比 Accuracy 低 2.4~3.3 个百分点，这是类别不均衡的直接结果：sports 占了 75% 的样本，把 Accuracy 拉高了，而 Macro-F1 给少数类 business 和 politics 同等权重，更能反映模型在少数类上的分类能力。其中 Word Frequency 的 Macro-F1 最高（0.9542），BERT 其次（0.9522），说明这两种方法在少数类上相对更稳。

六、代码结构与运行说明

```
HW-1/
├── data/                       # nyt.csv, ag.csv, glove/, nyt_{train,val,tes
t}.csv
├── code/
│   ├── utils.py                # 分词、数据加载、Accuracy/Macro-F1 计算
│   ├── prepare_data.py         # seed=42 打乱 + 80/10/10 划分
│   ├── task1_bow.py            # Task 1：Binary BoW / Word Frequency + LR
│   ├── task2_word2vec.py       # Task 2：GloVe / W2V(AG) / W2V(NYT) + LR
│   ├── task3_bert.py           # Task 3：BERT 微调
│   └── run_all.py              # 一键运行全部实验
└── results/results.jsonl       # 各实验指标
```

```
python -m venv .venv && pip install pandas scikit-learn gensim transformers t
orch
cd code
python prepare_data.py          # 数据划分
python run_all.py               # 依次运行全部实验（或分步运行单个 task）
```

更详细的运行说明见代码包中的 `README.md`，完整代码与运行说明已上传至 GitHub 仓库：
https://github.com/LittleFeng-notBot/Natural-Language-Processing

七、结论

本次作业实现并比较了三类文本表示方法。在 NYT 三分类任务上，两种词袋表示配合 Logistic Regression 效果最好（Accuracy 98.2%，Macro-F1 95.4%）；三种 100 维词向量平均的方法略低（Accuracy 97.7%~98.0%），其中用 9 万条 AG News 训练的 Word2Vec 已经接近公开预训练的 GloVe；BERT 微调在 max_length=64 的限制下取得 Accuracy 97.8%、Macro-F1 95.2%。总体来看，在这类关键词信号强、文本很长的主题分类任务上，覆盖全文的稀疏表示依然很有竞争力；词向量平均会损失一部分信息，效果受词表覆盖的影响；预训练模型的表现则明显受输入长度的限制。